

Труды Института востоковедения РАН. 2021. Вып. @@. С.238-247.
Proceedings of the Institute of Oriental Studies of RAS. 2021;(@@):238-247.

Научная статья

УДК 811.211

doi:@@

Новое в санскритской компьютерной лингвистике

Марцис Юрьевич Гасунс

независимый исследователь, Краснодар, Россия, gasyoun@ya.ru,

<https://orcid.org/0000-0003-4513-884X>

Аннотация. Корпусная лингвистика больше десяти лет тому назад стала стандартом для описания русской грамматики в рамках «Русской корпусной грамматики». Хотя первый санскритский корпус увидел свет в том же далеком 2010 г., а «Параллельный санскритско-русский корпус» спустя еще три года, санскритологи далеки от написания санскритской грамматики на основе корпуса. Однако уже известно, какой части крупных словарей достаточно для покрытия нужд корпуса (от 25000 до 91000 лемм). Упомянуты два направления из области OCR: с подключением грамматики и без.

Ключевые слова: санскрит, лексикография, параллельный корпус, OCR, Google Vision, древнеиндийский язык

Для цитирования: Гасунс М.Ю. Новое в санскритской компьютерной лингвистике // Труды Института востоковедения РАН. 2021. Вып. @@. С.238-247. <https://doi.org/@@>

Original article

Recent trends in Sanskrit computational linguistics

Mārcis Yu. Gasūns

Independent researcher, Krasnodar, Russia, gasyoun@ya.ru, <https://orcid.org/0000-0003-4513-884X>

Abstract. Russian corpus linguistics became the standard for describing Russian grammar within the framework of the «Russian Corpus Grammar» more than ten years ago. Although the first Sanskrit corpus was published back in 2010, and the «Parallel Sanskrit-Russian Corpus» three years later, Sanskrit scientists are still far from writing a Sanskrit grammar based on the data from corpus. But they have already found out which part of the dictionary is enough to cover the needs of the corpus (from 25.000 to 91.000 words). Two future paths of OCR are mentioned: involving grammar and without it.

Keywords: Sanskrit, lexicography, parallel corpus, OCR, Google Vision Old Indian language

For citation: Gasūns M. Recent trends in Sanskrit computational linguistics. *Proceedings of the Institute of Oriental Studies of RAS.* 2021;(@@):238-247. (In Russ.). <https://doi.org/@@>

1. Взаимодействие словаря, грамматики и корпуса

На конференции «Востоковедные чтения 2021. Сочетаемость языковых единиц и языковые модели. Памяти З.М. Шаляпиной (1946-2020)» (ИВ РАН, Москва, 14-15 апреля 2021 г.) после доклада «Параметрический анализ «Санскритско-русского словаря» В.А. Кочергиной» состоялся обмен мнениями, достойный послужить введением к моему обзору событий последних тридцати лет в компьютерной санскритологии. Позвольте процитировать реплику С.А. Крылова: «словарь и грамматика представляют собой непосредственно данность, по которой мы закономерно судим о языке, но пора добавить третий вид источников для санскритологии, а именно корпуса. Мы судим о языке по его словарям, грамматике и корпусам. Последние годы роль корпусов заметно возросла, теперь некоторые теоретики и вовсе отрицают значимость словарей и грамматик как источников информации. Что, конечно, представляет собой отчасти полемическую крайность, но имеет свои основания. Дело в том, что создатели «Словаря языка Пушкина» во главе с Г.О. Винокуром и предыдущие филологи тоже фактически имплицитно опирались на какие-то аналоги корпусов, но эти корпуса существовали в их психике как в психике начитанных филологов. Дело в том, что всякий начитанный филолог имеет своего рода корпус в своем мозгу, это отмечал в последнее время А.Д. Шмелев, который на основании этого впадает в обратную крайность, а именно в отрицание значимости корпусов. С точки зрения реалистичности надо признать, что словари, грамматики и корпуса скорее дополняют друг друга, но не могут заменить».

И следом слова А.А. Кротова: «Корпусом являлись те тексты, которые указаны и расписаны до одного слова составителями словаря языка Пушкина. Поэтому все произведения, которые они взяли, являются корпусом этого словаря. Все словари опираются на корпус каких-то расписываемых текстов. Поэтому корпус это не нечто новое, это – полуфабрикат, это – предсловарь, несделанный словарь. Для параметрического анализа лексики корпусá на сегодняшний день оказываются непригодны по одной важной причине – еще не научились компьютерным образом достоверно извлекать синонимы из данных корпусов и распределять значения. Когда это будет сделано, тогда можно будет опираться не только на словари, но и на корпуса. На сегодняшний день такой возможности пока нет».

Есть два принципиально разных пути. Есть намерение имитировать размах крыльев птицы, а есть путь создания самолета. Мы не пытаемся имитировать Панини, потому что на сегодняшний день компьютер этого сделать не может. Разработки последних десятилетий привели нас в тупик. В частности это видно по работам американского профессора Питера Шарфа, ученика величайшего паниниста современности Дж. Кардоны. Его код закрыт. Двадцать лет спустя он даже сам не смог воспроизвести то, что уже работало прежде – полуавтоматическая разметка морфологии «Повести о Раме» из «Махабхараты». Поэтому мы не пытаемся воссоздать древнеиндийскую грамматику так, как она была создана. Мы пытаемся идти путем застывшей парящей птицы, то есть путем самолета. Это принципиально разные вещи.

Зачем компьютеру санскрит? На этот вопрос впервые в 1985 году в журнале «Artificial Intelligence» пытался ответить американский ученый Рик Бригс [Briggs 1985], но дальше его предположений о пригодности санскрита как основы для

языка программирования будущего дело не пошло. Способы архивации, задействованные внутри санскрита и для описания санскрита испокон веков, остались невостребованными вне воображения сотрудника NASA.

Тогда спросим иначе. А зачем санскриту компьютер? Есть такие показатели, которые мы можем замерить хоть в рамках выписок из текстов, хоть в рамках электронного корпуса, но с совершенно разными трудозатратами. Например «формульность» в эпосе можно посчитать руками, а можно – используя возможности регулярных выражений и сведений о сочетаемости слов, посчитанных компьютером. Может ли компьютер понимать, читать и говорить на санскрите? На этот вопрос до сих пор нет удовлетворительного и однозначного ответа. Для того чтобы определить количество морфем в санскрите, ученые, начиная с пионера американской санскритологии У. Уитни [Whitney 2000], давно привлекают количественные показатели.

Так, например, в мировой практике санскритской лексикографии применение способов автоматизации работы с данными встречается еще крайне sporadically, а в области лексикографической типологии мы и вовсе делаем первые шаги. Однако есть области, в которых российская санскритология опережает мировые достижения. Мнение о мнимой отсталости русской индологии часто ошибочно. Проиллюстрируем данное утверждение несколькими примерами, добытыми в России.

2. Количество слов в санскрите

Сколько слов в санскрите? Известно, например, что в «Сводном списке слов словарей санскрита» 385 000 слов. Первоначально в 2014 г. мы составили конкорданс глагольных корней, а теперь завершили работу над сводным указателем санскритских суффиксов. И мы готовы ответить на столь простой, но тем не менее интересный вопрос. Соединяя 20 превербов и их сочетания с 850 корнями и 305 первичными и вторичными суффиксами, мы получаем почти все 385 000 слов. Столько «нормализованных», приведенных к единому способу записи слов можно найти во всех современных двуязычных и толковых санскритских словарях вместе взятых.

Рассмотрим частеречный срез на одном примере, на глаголах. Если опираться на словарь, то в санскрите около 10500 глаголов (согласно составленному на его основе «Сводному списку санскритских глаголов» с примерами из картотеки корпуса). С учетом сочетаний корней и приставок в словаре Monier-Williams (MW 2021) из пяти теоретически мыслимых сочетаний превербов самый длинный нам известный пример – это глагол *samabhivṛyāhāra* «упоминание вместе» = *sam* + *abhi* + *vi* + *āñ* + *hr*, где *sam*, *abhi*, *vi* и *āñ* – четыре преверба, *hr* глагольный корень «брать».

Каждая словоформа в «Сводном списке санскритских глаголов» подкреплена санскритской цитатой. Например, начало словарной карточки корня *āp* выглядит следующим образом:

√āp 1. P.

to come to any one, to enter, to equal, to fall, to fall upon, to gain, to meet with, to obtain, to occupy, to overtake, to pervade, to reach, to suffer, to take possession of, to undergo

āpnomi – *āpnomi saphalāṃllokāṃstat karma brūta māciram* / MBh, 1, 220, 10.2 (Ind. Pr. 1. sg. √āp 1. P.)

āpnoti – *bhogenā mokṣam āpnoti katham vadasi yogabhṛt* // MBhT, 3, 1.3 (Ind. Pr. 3. sg. √āp 1. P.)

āpsgplaḥ – *ātmānam ātmanā hatvā kiṃ dharmaphalam āpsgplaḥ* // MBh, 12, 7, 4.2 (Ind. Pr. 1. pl. √āp 1. P.)

āpnvanti – [...] *te balavīryayuktāḥ samāḥ śataṃ jīvitam āpnvanti* // AHS, Utt., 39, 162.2 (Ind. Pr. 3. pl. √āp 1. P.)

āpnuyām – *sarvajñanītyanutsargād bodhiṃ kiṃ nāpnuyāmaham* // BoCA, 7, 19.2 (Opt. Pr. 1. sg. √āp 1. P.)

āpnuyāḥ – [...] *no 'smān nirayānmokṣas tvaṃ ca putrāpnuyāgatim* // MBh, 3, 94, 14.2 (Opt. Pr. 2. sg. √āp 1. P.)

āpnuyāt – *bhogenā siddhiṃ āpnoti bhogenā mokṣam āpnuyāt* // MBhT, 3, 2.3 (Opt. Pr. 3. sg. √āp 1. P.)

āpnuyāma – *pūnyam evāpnuyāmeḥa pāpaṃ pāpopasevanāt* // MBh, 3, 1, 26.2 (Opt. Pr. 1. pl. √āp 1. P.)

āpnuyuh – *athāpnuyuh padaṃ śākram iṣtvā kratuśataṃ vidheḥ* // MrgTī, Vidyāpāda, 2, 11.2, 15.1 (Opt. Pr. 3. pl. √āp 1. P.)

āpnuhi – *dharmeṇa caturo varṇān pālayan kleśam āpnuhi* // Rām, Ay, 98, 57.2 (Imper. Pr. 2. sg. √āp 1. P.)

āpnotu – *nṛpo 'bravītsāñjalirāgatasprho yatheṣṭamāpnotu bhavānavighnataḥ* / BCar, 11, 72.1 (Imper. Pr. 3. sg. √āp 1. P.)

Список упорядочен по алфавиту и каждый приставочный глагол рассматривается как отдельная запись без указания на связь с исконным корнем. DCS 2021 опирается на словник словаря MW, отсюда и отсутствие связей приставочных корней с корнями «голыми». Сбросить словарь с корабля современности пока остается недостижимой мечтой яростных сторонников чистых корпусов.

Полученная цифра вполне сопоставима с количеством глаголов в русском или современном немецком языке. Интересно, что не только количество глаголов сопоставимо, как показано выше, но, в продолжение [Гасунс 2014], по общей оценке А.А. Зализняка, «число корней может быть в разных языках различно, но чаще всего порядка 2 – 3 тысячи» [Зализняк 2008]. Списки корней, прилагаемые к грамматикам, в счет не идут – их количество обычно исчисляется несколькими сотнями, изредка одной или двумя тысячами. Исключением среди грамматик, понимаемых в широком смысле, может послужить, например, пятитомный справочник *Urasargārtha Candrikā* [Śāstrī 1981], посвященный санскритским превербам (*upasarga*). Он заведомо полнее корпуса.

Даже корпуса? Далеко не все многообразие возможных сочетаний превербов представлено в корпусе и вряд ли когда-либо в обозримом времени будет. «Дополнительный том пополняемого санскритского словаря» (NWS 2021), завершённый в 2016 г., где под словом «словарь» подразумеваются Петербургские словари О. Бётлинга, «Большой» и «Малый», основан на 2590 источниках. Из них 171, в том числе вторичные, опубликованы за последние 140 лет и, собственно, составляют часть пополнений, расширений языка. Подобное количество источников в несколько раз превосходит количество привлечённых источников в любом полностью завершённом санскритско-санскритском или санскритско-двуязычном словаре и почти в два раза – в задуманном, но «незавершённом» словаре из Пуны (EDSHP 2021) с его 1500 заявленными первичными источниками, из кото-

рых тридцать лет сорок ученых делали выписки вплоть до 1976 года (года выхода первого тома) и которые еще три тысячи лет предстоит обрабатывать, таким образом сделав его самым долгим заведомо провальным словарным начинанием в истории человечества.

Корпуса имплицитно содержат сведения о частности и продуктивности, чего почти нет в грамматиках и о чем лишь косвенно можно судить из словаря. Заметим, что частотность, в частности, достаточно последовательно, хотя и не всегда верно, прописана в «Учебнике санскрита» В.А. Кочергиной, чего нет даже в некоторых куда более полных грамматиках. А полноценного частотного санскритского словаря на основе корпуса все еще не существует. А что доступно уже сейчас? Мы знаем многое о глаголах, нам доступны десятки тысяч контекстов. Так, например, наибольшее количество примеров употребления из оцифрованной санскритской литературы и разных словоформ, засвидетельствовано для следующих глаголов: *kṛ*, *vac*, *bhū*, *as*, *gam*, *dṛś*, *da*, *brū*, *sthā*, *jan*, где корень *kṛ* не только самый частотный, но у него засвидетельствованы целых 250 финитных словоформ (из около 800 возможных) в отличие, например, от *añj* с 1 формой:

karomi, *kurmi*, *kurve*, *kṛnomi*, *kṛñve*, *kṛñoṣi*, *karṣi*, *kuruse*, *kṛṣe*, *kṛñuse*, *karoṣi*, *kṛñute*, *kurute*, *kṛnoti*, *karoti*, *kurvaḥ*, *kṛnuthaḥ*, *kṛthaḥ*, *kurvāte*, *kurutaḥ*, *kṛnutaḥ*, *kurmaḥ*, *kṛnmaḥ*, *kurmahe*, *kṛnmasi*, *karavāmahe*, *kṛnmahe*, *kṛnutha*, *kṛtha*, *kurutha*, *kṛnvate*, *kurvate*, *kṛnvanti*, *kurvanti*, *kurvīya*, *kuryām*, *kuryāḥ*, *kurvūthāḥ*, *kurvīta*, *kṛnvīta*, *kriyāt*, *kuryāt*, *kuryātam*, *kuryātām*, *kuryāmaḥ*, *kurvīmahi*, *kuryāma*, *kuryāta*, *kurvīran*, *kuryuḥ*, *karavai*, *karavāni*, *kuru*, *kṛnuhi*, *kuruṣva*, *kṛnu*, *kṛnutāt*, *kurutāt*, *kṛnuṣva*, *kurutām*, *karotu*, *kṛnutām*, *kṛnotu*, *karavāva*, *karavāvahe*, *kurutam*, *kṛnvāthām*, *kṛnutam*, *karavāmaḥ*, *karavāmahai*, *karavāma*, *kuruta*, *kṛnuta*, *kurudhvam*, *kṛnotana*, *kṛnota*, *kṛnudhvam*, *kurvatām*, *kṛnvantu*, *kurvantu*, *akaravam*, *akaroḥ*, *akṛnoḥ*, *akṛnuta*, *akuruta*, *akṛnot*, *akarat*, *akurvahi*, *akṛnutam*, *akurvātām*, *akṛnutām*, *akurutām*, *akurmahi*, *kurma*, *akṛnotana*, *akṛnudhvam*, *akṛnota*, *akṛnvan*, *akṛnvata*, *akurvan*, *akurvata*, *akurvanta*, *kariṣyāmi*, *kariṣye*, *kariṣyase*, *kariṣyasi*, *kariṣyate*, *kariṣyati*, *kariṣyāva*, *kariṣyāvaḥ*, *kariṣyāvahe*, *kariṣyathaḥ*, *kariṣyataḥ*, *kariṣyete*, *kariṣyāmahe*, *kariṣyāmaḥ*, *kariṣyatha*, *kariṣyanti*, *akariṣyam*, *akariṣyaḥ*, *kariṣyāḥ*, *akariṣyata*, *akariṣyat*, *kariṣyāma*, *kariṣyadhvam*, *kartāham*, *kartāsmi*, *kartāsi*, *kartā*, *kartārau*, *kartārah*, *akri*, *akaḥ*, *akṛthāḥ*, *akṛta*, *askṛta*, *akṛtam*, *akartām*, *akrātām*, *akratām*, *akarma*, *akarta*, *akran*, *akrata*, *akaram*, *akarah*, *akarat*, *akaran*, *acikṛthāḥ*, *acikarat*, *acikaran*, *akārśam*, *akārṣīḥ*, *akārṣīt*, *akārṣuḥ*, *kriyāsam*, *kriyāsmā*, *kriyāsuḥ*, *cakre*, *cakara*, *cakāra*, *cakriṣe*, *cakṛṣe*, *cakartha*, *cakrathuḥ*, *cakrāthe*, *cakrāte*, *cakratuḥ*, *cakṛma*, *cakra*, *cakruḥ*, *cakrire*, *kriyate*, *kriyete*, *kriyante*, *kṛnavā*, *kṛnavai*, *karavaḥ*, *kṛnavah*, *kṛnavase*, *karavāt*, *kṛnavat*, *kṛnavate*, *karavat*, *kṛnavāva*, *kṛnavāvahai*, *karavāvahai*, *kṛnavāma*, *kṛnavāmā*, *kṛnavāmahai*, *kṛnavatha*, *kṛnvaite*, *kṛnavan*, *kṛnavanta*, *karavan*, *kriyatām*, *kriyantām*, *akriyata*, *akriyanta*, *akāri*, *kriyeta*, *kriyeran*, *karam*, *kārṣīḥ*, *kṛṣīṣthāḥ*, *karoh*, *kārṣīḥ*, *kṛthāḥ*, *kaḥ*, *kṛta*, *karot*, *karat*, *kārṣīt*, *kṛtam*, *karma*, *kārṣīta*, *kartana*, *kṛdhvam*, *kurvan*, *kārṣuḥ*, *kran*, *kriyāma*, *kṛdhī*, *kṛṣya*, *kṛdhi*, *kartam*, *karatam*, *karatām*, *karta*, *cakriyāḥ*, *kṛnavam*, *kuruthāḥ*, *kṛnvata*, *cakaram*, *acakrat*, *acakriran*, *karā*, *karāni*, *karah*, *karasi*, *karase*, *karate*, *karati*, *karāthah*, *karathah*, *karataḥ*, *karāmahe*, *karāma*, *karan*, *karanti*.

Невооруженным глазом заметна некоторая корреляция между количеством словоформ и частотностью употребления в целом. Но более глубокие корреляции, как, например, про то, что глаголы распадаются на «две большие группы по способу образования презенса и перфекта» [Старостин 1985] компьютерным вычислениям недоступны, требуется человеческий гений.

Независимо от того, кто именно автор словаря, важнейшие глаголы санскрита представлены во всех словарях и глоссариях, то есть субъективный фактор составителя словаря – фактор отнюдь не определяющий и порой заметно переоценен. Иначе бы словник П.С. Палласа не совпадал на две трети с базовым списком М. Сводеша (см. по этому вопросу [Кретов, Титов 2006], который, в свою очередь, опираясь опять же на совершенно субъективные факторы, имеет три редакции, а не одну, единственно возможную. Не бывает бесстрастной, безличностной лексикографии.

Но «вольность» составителя словаря, согласно двадцатилетним наблюдениям над более чем шестьюдесятью двуязычными словарями разных семейств языков воронежского языковеда проф. А.А. Кретова, сводится в рамках словника всего к 1/3 вокабул. То есть даже если человек, который составил словарь, вам, например, как личность глубоко неприятен, то он смог бы испортить в лучшем случае вряд ли заметно больше трети словаря. А так как в словаре В.А. Кочергиной прослеживается преемственность от канонических немецко-санскритских словарей, то следует признать, что часть претензий к нему совершенно надуманны, *ad hominem*.

Заметим, что работы с корпусом все равно ведутся через призму словарей. Иначе как знать, на какие единицы членить тексты? Не бывает девственных корпусов, где нет или никогда не было ни одного словаря.

В мире согласно скромным оценкам современных ученых насчитывается 30 миллионов санскритских рукописей, большинство из которых никогда не были не то, что оцифрованы, но и никогда не будут изданы или отредактированы. Соответственно работы хватило бы еще как минимум до конца следующего столетия. Нам нужен компьютер не столько потому, что мы, предположительно, стали глупее предшественников и наши познания уже не энциклопедичны. Компьютер не заменяет санскритолога, но без компьютера современный санскритолог будет тратить неоправданно, избыточно много времени на достаточно тривиальные операции. И, собственно, нередко вынужденно тратит, совершая мартышкин труд.

Однако вернемся к «Сводному списку слов в санскрите», который в обработанном виде должен войти в разрабатываемый мной двухтомный «Обратный словарь санскрита» (7 и 8 тт. серии «Bibliotheca Sanscritica»). Если брать не «нормализованную» запись, а в том виде, в каком вокабулы записаны в самих словарях, получается всего 430 000 лемм в санскрите. Если же снять разности орфографии, то остаются уже озвученные 385 000 слов. За последние 14 лет в Кёльнских словарях группой энтузиастов с моим участием было исправлено порядка 10 000 опечаток, существенная доля из которых приходилась на заглавные слова. Лишь в 2021 г. нами начата планомерная сверка содержания самих статей, опираясь на разные вспомогательные алгоритмы. И этот список распisan по словарям. Семь лет как доступен сводный список санскритских слов, но кроме горстки разработчиков он, конечно, остается совершенно недооцененным. Помимо этого, лет двадцать как существует «Сводный список словоформ санскрита» – несколько сотен тысяч ячеек таблицы, калькуляция знаменитого парижского математика Жерара Юэ (HWNORM).

Конечно, словоформы Юэ порождены компьютером (на основе несколько тысяч строк кода) и соответственно содержат разные неточности, например, не

учитываются известные даже из элементарных курсов грамматики исключения. Есть надежда, что еще через 25 лет ошибок будет значительно меньше, если генератор не будет вовсе заброшен, впрочем, доступ к исходному коду на этот раз приоткрыт. Жаль, что разные мимолетные университетские проекты в той же Индии, изобретая Yet Another Sanskrit Sandhi Engine, не учитывают разработки коллег старшего поколения и набивают все те же шишки, занимаясь в погоне за мнимой новизной регенерацией несуществующих санскритских слов из года в год.

Последние двадцать строк «Сводного списка слов в санскрите» в транслитерации SLP1 выглядят следующим образом (заглавными буквами набраны аббревиатуры словарей согласно CDSD 2021):

hvAtavya: hvAtavya: AP, CAE, MW, PW, PWG
hvAtf: hvAtf: MW, MW72
hvAna: hvAna: BEN, CAE, MW, MW72, PW, PWG, SHS, STC, VCP; hvAnaM: AP90
hvAnam: hvAnam: AP
hvAnIya: hvAnIya: MW, MW72
hvAya: hvAya: MW, PW, PWG
hvAyaka: hvAyaka: AP, MW, PW, PWG
hvAyakIy: hvAyakIy: PW
hvAyakIya: hvAyakIya: MW
hvAyayitavya: hvAyayitavya: MW
hvAyin: hvAyin: MW, MW72
hvAra: hvAra: CAE, CCS, GRA, MD, MW, MW72, PW, PWG
hvArya: hvArya: CAE, CCS, GRA, MW, MW72, PW, PWG; hvAryaH: AP
hvAla: hvAla: CAE, CCS, MW, PW, PWG; hvAlaH: AP
hvf: hvf: AP, AP90, BEN, BOP, BUR, CAE, GRA, KRM, LAN, MD, MW, MW72, SHS, SKD, STC, VCP, WIL, YAT
hvfIa: hvfIa: MW, MW72
hvF: hvF: MW
hve: hve: AP, AP90, BEN, BOP, BUR, MW, MW72, SHS, SKD, VCP, WIL, YAT
hveY: hveY: KRM
hveya: hveya: MW, MW72

SLP1 показала себя как наиболее надежная система транслитерации для хранения данных для санскрита, так как в отличие от НК (= «киотицы»), например, в SLP1 можно верно отразить редкие случаи зияния в санскрите без дальнейшей потери данных при обратной конвертации, например, в деванагари. Другой такой транслитерации нет.

3. Технологии распознавания санскритского текста

На сегодня самым продвинутым OCR алгоритмом для работы с брахми-производными письменностями является алгоритм Google Vision, сменивший на этом посту несколько лет тому назад Tesseract. Чем он хорош? Тем, что в Google в США работают много индийских программистов, около 2016 г. они сочли возможным улучшить степень распознавания санскрита в целом и деванагари в частности. Сайт SCR 2021 примечателен тем, что его основатель Мартин Глюкман из Южной Африки, послуживший инициатором данного углубленного обучения OCR алгоритмов, обычно платный сервис Google Vision представляет бесплатно в рамках своей

образовательной лицензии. Иначе 3370000 распознанных картинок обошлись бы нам в сумму около 5000 долларов. То есть сперва обучил до того отстающий алгоритм, а потом сделал общедоступным.

Помимо этого у нас есть незаслуженно отодвигаемые отечественные разработки, которые можно было бы применить, например, к двадцати двум разновидностям всевозможных южноазиатских письменностей в Сериндийском фонде ИВР РАН. Это достаточно нетривиальная задача даже для более зрелых алгоритмов ввиду малого количество одинаково оформленного материала для обучения, но первичная помеха этому, помимо отсутствия финансирования, именно закрытость фондов.

Подходов несколько. Подход отечественного исследователя А. Строганова принципиально отличается от подхода Google Vision, так как он опирается на вспомогательные инструменты для достижения более высокого процента точности распознавания. То, что распознается, корректируется на сервере с применением грамматического анализа, но пока лишь удовлетворительно для тибетского языка.

Дальнейшая судьба компьютерной санскритологии связана с тем, что мы должны объединить усилия добровольцев с возможностями искусственного интеллекта. По отдельности ни те, ни другие не могут ничего или могут ничтожно мало. В 1985-м еще не было компьютерного ресурса. Ресурс теперь появился, но мы его не используем должным образом, используя компьютер часто лишь как печатную машинку.

Относительно недавно с помощью добровольцев мы начали распознавать разные санскритско-русские глоссарии и словари. Шесть лет назад, например, был издан репринтом словарь О. Фриша, словарь малого объема, 8150 слов, а теперь он доступен электронно. Издаваемые мною в рамках серии «*Bibliotheca Sanscritica*» словари полностью или частично оцифрованы и доступны публично (например, помимо изданных у нас, KEWA 2021). Партизанской предыстории индологии пора поставить точку. Есть задачи, где нужно действовать сообща, и благоприятное время уходит невозвратно.

Что такое частичная оцифровка? Разрезанным картинкам (= словарным статьям) присваивается словесный заголовок или выписываются выборочные грамматические характеристики. Даже в такой компьютерной среде есть определенные преимущества, и это может дать нам новые инструменты, которых не могло быть в бумажных оригиналах. Двадцать пять лет спустя появления первой оцифровки словаря Monier-Williams, мы лишь приближаемся к реализации высказанных еще в конце 80-х годов идей. Те самые «современные методы научного исследования, включая вычислительные машины», о которых востоковеды прежних поколений не смели и мечтать. Но кто из современных санскритологов может, например, составить регулярное выражение и обработать полученные данные?

Еще одна наша разработка, о которой хотелось бы упомянуть – режим *simple*, или упрощенный поиск, по словарям санскрита на сайте Кёльнского университета (CDS 2021). Если человек не знает, что он ищет, алгоритм *simple* пытается понять, что же на самом деле он мог иметь в виду. Не только в южной Индии люди записывают санскрит диковинными способами, но и у нас в русскоязычной среде находятся умельцы. Наша задача – придумать набор алгоритмов, чтобы поле от-

вета никогда не пустовало. И, соответственно, алгоритм поправит лишние буквы или подставит недостающие. Как и прежде, сосуществуют различные системы транслитерации, которые, например, остались только в Индии, но, несмотря на это, довольно распространены – алгоритм *simple* поможет отгадать и их.

Мы делаем первые шаги, чтобы словарь, корпус и грамматику срастить вместе. Удачный пример воплощения схожего подхода – Параллельный санскритско-русский корпус (PSRK 2021). Словарь получает совершенно новый функционал. Мы впервые можем добавить не только санскритско-русские отсылки, а через немецкий словарь Грассмана к Ригведе, например, выйти на английский перевод столетней давности, заново связав лемму и контекст, откуда она взята – добавив все доступные нам на сегодня оцифрованные переводы. А когда-то, возможно, сможем даже дополнить его французским переводом Л. Рену – во славу отечественного востоковедения.

Последнее достижение отечественных разработок было начато еще в 2013 г. RKG 2021 – это целиком Ригведа, большая часть Атхарваведы, Махабхараты и половина Рамаяны, целиком запланирован «Океан сказаний» Сомадевы. То есть впервые в мировой науке представлены крупные пласты разных хронологических срезов древнеиндийского языка вместе с переводами: санскрит ведийский, эпический и классический. Корпус столь крупного языка как санскрит (Grosskorpus-Sprache словами мэтра мировой санскритологии М. Майрхофера) не создается в одиночку, у нас в «Обществе ревнителей санскрита» десятки добровольцев и координирует их усилия наш бессменный Анатолий Артеменко из Одессы. Такого корпуса нет нигде больше.

Источники

CSDS 2021 – *Cologne Digital Sanskrit Dictionaries*

URL: <https://www.sanskrit-lexicon.uni-koeln.de/>. Дата обращения 15.07.2021.

EDSHP 2021 – *An Encyclopedic Dictionary of Sanskrit on Historical Principles*.

URL: <https://sanskrit-lexicon.uni-koeln.de/scans/PDScan/2020/web/>. Дата обращения 15.07.2021.

MW 2021 – *Monier-Williams Sanskrit-English Dictionary*.

URL: <https://sanskrit-lexicon.uni-koeln.de/scans/MW72Scan/2020/web/>. Дата обращения 15.07.2021.

PSRK 2021 – *Параллельный санскритско-русский корпус*.

URL: <http://samskrutam.ru/parallel-corpus/>. Дата обращения 15.07.2021.

KEWA 2021 – *Kurzgefasstes etymologisches Wörterbuch des Altindischen*.

URL: <http://samskrutam.ru/sanskrit-lexicon/KEWA/>. Дата обращения 15.07.2021.

SLS 2021 – *Сводный список санскритских глаголов*.

URL: <https://samskrutam.ru/sanskrit-lexicon/sopasarga/>. Дата обращения 15.07.2021.

NWS 2021 – *Kumulatives Nachtragswörterbuch des Sanskrit*.

URL: <https://nws.uzi.uni-halle.de/>. Дата обращения 15.07.2021.

SCR 2021 – *SanskritCR*.

URL: <https://ocr.sanskritdictionary.com/>. Дата обращения 15.07.2021.

DCS 2021 – *Digital Corpus of Sanskrit*.

URL: <http://sanskrit-linguistics.org/dcs/>. Дата обращения 15.07.2021.

RKG 2021 – *Русская корпусная грамматика*.

URL: <http://rusgram.ru>. Дата обращения 15.07.2021.

HWNORM – *Headword normalization for Cologne dictionaries*

URL <https://github.com/sanskrit-lexicon/hwnorm1> Дата обращения 15.07.2021.

Литература

1. Гасунс М.Ю. *Состав и строй древнеиндийских корней: история изучения*. Авто-реферат дис. ... кандидата филологических наук. М., 2014. 23 с.
2. Зализняк А.А. *О профессиональной и любительской лингвистике*. 2008.
URL <https://goldrussian.ru/o-professionalnoj-i-ljubitelskoj-lingvistike.html>. Дата обращения 01.08.2021.
3. Кочергина В.А. *Санскритско-русский словарь*. / Под ред. В.И. Кальянова. С приложением «Грамматического очерка санскрита» А.А. Зализняка. М.: Русский язык; 1987 (1978).
4. Кочергина В.А. *Учебник санскрита*. М.: Филология; 1994. 336 с.
5. Кретов А.А., Титов В.Т. Алгоритм позиционного выявления синонимии // Вестник ВГУ. Серия «Системный анализ и информационные технологии». 2006. № 1.
6. Старостин С.А. Парадигматические типы древнеиндийского глагола // *Древняя Индия. Язык. Культура. Текст*. М., 1985. С. 272
7. Фриш О. *Санскритская хрестоматия*. В 2 т. Т. 2. Словарь / сост. О. Фриш; редактор В. Поржизка; автор предисл. и биогр. М. Ю. Гасунс. – М.: «АБВ»; 2015. (Репр. воспроизведение изд. / сост. О. Фриш. – Прага: Изд. АН Чехословакии; 1956). 355 с.
8. Briggs R. Knowledge Representation in Sanskrit and Artificial Intelligence // *AI Magazine*. Vol. 6. № 1. 1985. P.32
9. Śāstrī cārūdeva. *Upasargārtha-candrikā* (= Лунный свет значений упасарг (превербов)). Delhi: Bhāratiya vidyā prakāśana, 1981. (In Sanskrit)
10. Whitney W.D. *The roots, verb-forms and primary derivatives of the Sanskrit language*. Dheli: Motilal Banarsidass; Reprint edition; 2000. 250 p.

Сведения об авторе

Марцис Юрьевич Гасунс – кандидат филологических наук, независимый исследователь.

Статья поступила в редакцию 10.06.2021; принята к публикации @.11.2021.

The article was submitted 10.06.2021; accepted for publication @.11.2021.